



Series temporales de convergencia para la optimización cooperativa de HRES–H₂

Lucas Erazo

Escuela de Ingeniería Informática
Pontificia Universidad Católica de Valparaíso

Profesor guía: Emanuel Vega Profesor correferente: Ricardo Soto

Septiembre de 2026

Estructura de la presentación

1. Problema y sistemas cooperativos
2. Series temporales y arquitectura propuesta
3. Modelo HRES2-H₂ implementado
4. Validación y posicionamiento
5. Plan de trabajo
6. Cierre

1. Problema y sistemas cooperativos

Exploración global

Recorre regiones distintas del espacio de soluciones y conserva diversidad.

Explotación local

Refina soluciones prometedoras y acelera la convergencia cerca de buenos óptimos.

Tensión principal

Demasiada exploración retrasa la convergencia. Demasiada explotación provoca convergencia prematura.

El mejor comportamiento depende del problema y también de la etapa de cada ejecución.

(Akbulut 2026; Vega et al. 2021; Wolpert y Macready 1997)

Pregunta central

¿Cuándo debe terminar la fase del solucionador activo y transferir el control a otro algoritmo?

Presupuesto fijo

Es simple, pero ignora la dinámica observada durante la ejecución.

Umbral manual

Depende de la escala del objetivo, el paisaje y el algoritmo monitoreado.

Indicador escalar

Resume el estado actual, pero puede confundir una meseta transitoria con estancamiento.

Política aprendida

Modela relaciones complejas, aunque requiere estados, entrenamiento y recompensas.

(Adriaensen et al. 2022; Pei et al. 2025; Talbi 2021)

Trabajo	Qué estudia o aporta
Żychowski et al. (2025)	Propone un portafolio de islas: metaheurísticas en paralelo intercambian soluciones y adaptan la migración.
Drake et al. (2020)	Revisan hiperheurísticas: una capa superior selecciona, genera o secuencia métodos de búsqueda.
Dokeroglu et al. (2024)	
Derbel y Verel (2011)	
Mambrini y Sudholt (2015)	DAMS permite que nodos distribuidos decidan qué metaheurística aplicar y qué información comunicar.
Pei et al. (2025)	Estudian cómo ajustar intervalos de migración o seleccionar operadores según las mejoras y el estado de búsqueda.

Decisión de coordinación: cuándo comunicar, qué transferir y qué solucionador continúa.

La literatura ya utiliza:

- mejora reciente del fitness;
- diversidad y características de población;
- historiales de operadores;
- características de trayectorias para selección y *warm-start*.

(Cenikj et al. 2026; Jankovic et al. 2022; Kostovska et al. 2022)

La trayectoria reciente del mejor resultado aún puede guiar mejor el cambio de solucionador

La propuesta convierte esa serie temporal en una señal de coordinación: distingue progreso sostenido de estancamiento persistente.


2. La convergencia como señal de coordinación

Objetivo general


Integrar la serie temporal de convergencia a la coordinación de metaheurísticas para dimensionar HRES-H₂. DTW/DDTW compara la trayectoria reciente con patrones de progreso y meseta.

- 1 Caracterizar el modelo, sus restricciones y no linealidades.
- 2 Construir ventanas móviles de la trayectoria del mejor valor objetivo.
- 3 Comparar cada ventana con progreso y meseta mediante DTW/DDTW.
- 4 Definir el intercambio de soluciones entre algoritmos heterogéneos.
- 5 Orquestar la alternancia entre exploración y explotación.
- 6 Validar el marco y estudiar su extensión mediante ε -restricción adaptativa.

Diagrama de flujo de la propuesta



La serie temporal revela el estancamiento



La información que faltaba en la coordinación

La forma de la ventana reciente permite comparar mejora sostenida con meseta antes de decidir si continúa el solucionador activo.

Esquema conceptual, no resultado experimental. Para minimizar LCOE se muestra una curva descendente; el detector implementado recibe $-\text{LCOE}$ como señal de maximización.

DTW: comparar la ventana con dos patrones

- 1 Tomamos los últimos W valores del mejor resultado: la ventana X .
- 2 Calculamos su distancia a una rampa de progreso r y a una meseta c .
- 3 La menor distancia indica qué patrón se parece más a la trayectoria reciente.

Por qué DTW

Dos trayectorias pueden mejorar con ritmos distintos. DTW alinea sus puntos antes de medir la diferencia.

DDTW

Compara los cambios entre iteraciones en lugar de los niveles.

$d(X, c) < d(X, r)$: la ventana se parece más a una meseta.

Esa comparación aporta evidencia; el cambio de solucionador exige además falta de mejora sostenida.

Poblacionales

GA	evolución y recombinación
PSO	movimiento social de partículas
GWO	jerarquía de búsqueda
WOA	rodeo y trayectoria espiral
EHO	dinámica de manada
ACO	muestreo desde memoria colectiva

Función dominante: diversificación y exploración global.

De trayectoria

SA	aceptación probabilística
TS	memoria tabú y aspiración
ILS	perturbación y búsqueda local
VNS	cambio sistemático de vecindad

Función dominante: intensificación y refinamiento local.

- 1 Una metaheurística ejecuta un bloque de iteraciones.
- 2 DTW/DDTW revisa si el mejor LCOE sigue mejorando.
- 3 Si detecta estancamiento, termina ese bloque.
- 4 Se guarda la mejor solución encontrada hasta ese momento.
- 5 Se elige otra metaheurística y se le entrega esa solución para comenzar.

¿Cómo se hace el cambio?

MH activa



alerta de estancamiento



otra MH

Ejemplo: PSO → SA → ABC.

La mejor solución se conserva y se entrega al receptor.

Warm start, en simple

Recibe la mejor solución; no parte de cero.
Población: inyección más candidatos nuevos.
Alternancia poblacional → trayectoria → poblacional; DTW/DDTW decide.

3. Modelo HRES2-H₂ implementado

WPEB publicado vs. implementación HRES2-H₂


Parámetro	WPEB de Li et al. (2024)	Implementación HRES2-H ₂
Variables de diseño	Razones eólica/electrólisis; capacidades continuas.	$\mathbf{x} = [P_{WT}, N_{el}, P_{bat}, \tau_{bat}]^T$; mixto.
Renovables	$P_{WT} + P_{PV} = 200$ MW.	Misma capacidad total fija; $P_{PV} = 200 - P_{WT}$ MW.
Electrolizador	Estación continua; caso óptimo E95 (95 MW).	$N_{el} \in \{10, \dots, 20\}$ módulos de 5 MW.
BESS	Fijo: $P_{bat} = 0.30P_{el}$ y 1 h.	$P_{bat} \in \{0, 5, \dots, 50\}$ MW; $\tau_{bat} \in \{1, 2, 4\}$ h.
Simulación y restricción	Despacho horario de 8.760 h; AGSR ≤ 20 %.	Mismo horizonte y AGSR; penalización de diseños inviables.
Optimización	Grid search + descenso de gradiente; minimiza LCOE.	DTW/DDTW: cambia solucionador, transfiere la mejor solución global y reporta LCOH.

Diferencia que se quiere medir

La física se conserva; la extensión añade variables discretas y cooperación adaptativa entre metaheurísticas.

Referencia: W190-P10-E95-B30, LCOE = 0.2692 CNY/kWh.

HRES-H₂: qué se dimensiona



Flujo de energía: renovables, batería y red

Flujo de producto: electrolizador → H₂

Variables que realmente optimiza el algoritmo

Variable	Qué representa	Dominio
P_{WT}	potencia eólica instalada	0–200 MW
N_{el}	módulos PEM de 5 MW	10–20 módulos
P_{bat}	potencia máxima BESS	0–50 MW, pasos de 5
τ_{bat}	duración nominal BESS	1, 2 o 4 h

Generación eólica

La velocidad del viento determina el factor horario $f_{WT}(t)$:

$$f_{WT}(t) = \begin{cases} 0, & v < v_i \text{ o } v \geq v_o, \\ \frac{v^3 - v_i^3}{v_r^3 - v_i^3}, & v_i \leq v < v_r, \\ 1, & v_r \leq v < v_o. \end{cases}$$

$v_i = 2.5$, $v_r = 10.5$ y $v_o = 25$ m/s. La potencia generada es $P_{WT}f_{WT}(t)$; la turbina nominal es de 5 MW.

Generación fotovoltaica

La irradiancia es el factor principal de la generación solar.

$$P_{PV}^{gen}(t) = P_{PV} g(t) \underbrace{0.90}_{\text{pérdidas}} \underbrace{C_T(t)}_{\text{temperatura}}$$

- $g(t)$ representa la irradiancia horaria: de noche es cero.
- $C_T(t)$ reduce el rendimiento cuando la celda se calienta.
- El factor se limita al intervalo $[0, 1]$.
 $NOCT = 47^\circ\text{C}$, $\gamma_T = -0.5\% / ^\circ\text{C}$; 0.90 representa pérdidas del sistema.

Potencia disponible cada hora:

$$P_{gen}(t) = P_{WT}f_{WT}(t) + P_{PV}f_{PV}(t) \leq P_{WT} + P_{PV} = 200 \text{ MW}.$$

HRES-H₂: cómo opera cada hora

- 1 Calcular $P_{\text{gen}}(t) = P_{\text{WT}}(t) + P_{\text{PV}}(t)$ a partir del clima.
- 2 Si $P_{\text{gen}}(t) \geq 0.30P_{\text{el}}$, alimentar el PEM hasta P_{el} .
- 3 Si no se alcanza ese mínimo, descargar BESS si hay energía; si no, detener el electrolizador esa hora.
- 4 El excedente carga el BESS hasta $SOC \leq P_{\text{bat}}\tau_{\text{bat}}$; lo restante se vende a la red.

Energía anual que recibe el PEM

$$E_{\text{el,annual}} = \sum_{t=1}^{8760} P_{\text{el,usada}}(t) \Delta t$$

$P_{\text{el,usada}}(t)$ es la potencia que realmente consume el PEM en la hora t ; con $\Delta t = 1$ h, la suma queda en MWh/año.

La simulación recorre las 8.760 horas.
La carga y descarga usan
 $\eta_{\text{ch}} = \eta_{\text{dis}} = \sqrt{0.90} \approx 0.9487$.

1. Energía que realmente usó el PEM

$$E_{\text{el,annual}} = \sum_{t=1}^{8760} P_{\text{el,usada}}(t) \Delta t$$

$P_{\text{el,usada}}(t)$ es la potencia realmente consumida en la hora t [MW]. Como $\Delta t = 1$ h, la suma da $E_{\text{el,annual}}$ en MWh/año: se usa el consumo del despacho, no $P_{\text{el}} \times 8760$.

2. Conversión de energía a masa

$$m_{H_2} = \frac{E_{\text{el,annual}} \cdot 1000 \cdot \eta_{\text{el}}}{HHV_{H_2}}$$

m_{H_2} : kg producidos por año.

$\eta_{\text{el}} = 0.75$: eficiencia, sin unidades.

$HHV_{H_2} = 39.4$ kWh/kg: energía por kg de H_2 .

1000: convierte MWh a kWh.

Costo nivelado de electricidad (LCOE)

$$\text{LCOE} = \frac{\text{NPC} \cdot \text{CRF}}{E_{\text{entregada,annual}}}$$

- *NPC*: costo presente neto: CAPEX, reemplazos y operación/mantenimiento.
- *CRF*: factor que convierte el *NPC* en costo anual equivalente: $\text{CRF} = \frac{r(1+r)^N}{(1+r)^N - 1}$.
- $r = 4.35\%$: tasa de descuento real; $N = 25$: años del proyecto.
- $E_{\text{entregada,annual}} = 1000(E_{\text{el,annual}} + E_{\text{grid,sales,annual}})$: energía anual contabilizada [kWh/año].

Restricciones y penalización

- $P_{\text{WT}} + P_{\text{PV}} = 200 \text{ MW}$;
- dominios mixtos de N_{el} , P_{bat} y τ_{bat} ;


Límite de exportación anual

$$\text{AGSR} = \frac{\sum_{t=1}^{8760} P_{\text{grid_sales}}(t)}{\sum_{t=1}^{8760} P_{\text{gen}}(t)} \leq 0.20$$

Si $\text{AGSR} > 0.20$, el modelo usa

$$f_{\text{pen}}(\mathbf{x}) = 100 + 10 \text{ AGSR}.$$

Cómo se integra el optimizador con el HRES



Interfaz cooperativa

El HRES no recibe una metaheurística específica: recibe candidatos factibles, devuelve indicadores comparables y conserva la mejor solución global para la siguiente época.

Resultados HRES2-H₂: métricas y configuración

31 corridas independientes

Variante	LCOE medio	LCOH medio	σ	Factibilidad / AGSR
DTW	0.267160	17.6314	0.000001	100 % / 20.00 %
DDTW	0.267160	17.6313	0.000005	100 % / 20.00 %

Mejor LCOE observado: 0.267159 CNY/kWh.

Configuración común encontrada

Eólica	174.47 MW
Solar PV	25.53 MW
Electrolizador	70.0 MW (14 módulos)
Batería	50.0 MW / 4 h
H₂ anual	8,862,879.4 kg


HRES2-H₂: comparación con solucionadores base

Método	LCOE medio (CNY/kWh)	Mejor LCOE (CNY/kWh)	σ (CNY/kWh)	AGSR (%)	Factibilidad (%)
Propuesto (DTW)	0.267160	0.267159	0.000001	20.00	100.0
Propuesto (DDTW)	0.267160	0.267159	0.000005	20.00	100.0
GWO	0.268066	0.267160	0.002815	19.42	90.3
VNS	0.267806	0.267159	0.002465	19.95	93.5
TS	0.267188	0.267159	0.000038	19.99	96.8
ACO	0.273288	0.267159	0.007584	18.95	93.5
ILS	0.267184	0.267171	0.000023	19.98	96.8
PSO	0.277289	0.274579	0.010939	19.85	83.8
WOA	0.277227	0.276524	0.009567	19.70	87.1
EHO	0.277728	0.276524	0.007382	19.92	80.6
SA	0.286431	0.281339	0.013206	19.35	87.1

Lectura del resultado


En 31 corridas, DTW y DDTW combinan la menor media y el mejor LCOE, AGSR en el límite permitido y factibilidad completa; los métodos base muestran mayor variabilidad y/o diseños inviables.

Resultados HRES2-H₂: convergencia del pipeline DTW



Las líneas verticales indican cambios de solucionador; la mejor solución global se conserva y la trayectoria se estabiliza en 0.267159 CNY/kWh.

Resultados HRES2-H₂: convergencia del pipeline DDTW



La señal derivativa mantiene la misma solución final; los cambios de metaheurística aparecen sobre los mismos plateaus de la trayectoria.


Posicionamiento frente al trabajo relacionado

Enfoque	Temporal	Cambia MH completa	Requiere aprendizaje	Señal principal
Migración adaptativa	parcial	sí	no	mejora, diversidad o estancamiento
Selección por trayectoria	sí	sí	sí	características y regresión de desempeño
DAC con aprendizaje	sí	sí	sí	estado aprendido y recompensa
Propuesta temporal	sí	sí	no	serie reciente del mejor valor objetivo, comparada con rampa y meseta

Diferenciación: la trayectoria de convergencia pasa de ser un resultado observado a una señal temporal que guía el intercambio entre metaheurísticas completas.

(Jankovic et al. 2022; Liu et al. 2025; Mambrini y Sudholt 2015; Reijnen et al. 2025)


Plan de trabajo (agosto–diciembre de 2026)



La primera entrega cierra la validación inicial (semana 6); luego se amplían el enfoque multiobjetivo, las metaheurísticas y los sistemas antes del informe final.

- ① Integrar la serie temporal del mejor valor objetivo a la decisión de coordinación entre metaheurísticas heterogéneas.
- ② Comparar la ventana reciente con patrones de progreso y meseta mediante DTW/DDTW para detectar estancamiento.
- ③ Un protocolo de transferencia que preserva la mejor solución global al cambiar de solucionador.
- ④ Una validación gradual en benchmarks y en el dimensionamiento HRES-H₂.
- ⑤ Una extensión para estudiar compromisos económicos y ambientales mediante ε -restricción adaptativa.

Banda Sakoe–Chiba: limitar el alineamiento



Azul: celdas que el algoritmo puede visitar. Rojo: camino óptimo del ejemplo.

Banda permitida

Solo visita celdas con $|i - j| \leq b$; así evita alineamientos entre puntos muy lejanos.

Recurrencia DTW implementada

$C_{ij} = |X_i - Y_j|$, con $D_{0,0} = 0$ y $D_{i,0} = D_{0,j} = \infty$.

$$D_{ij} = C_{ij} + \min \{ D_{i-1,j}, D_{i,j-1}, D_{i-1,j-1} \}$$

Tres movimientos: avanza X, avanza Y o avanzan ambas series.

Ejemplo e implementación

$W = 6$, $b = 2$: (3, 5) permitido; (1, 5) prohibido.

Ejemplo numérico: DTW con los tres movimientos

Misma forma, distinto ritmo: señal normalizada para maximización

$X = [.50, .50, .50, .56, .60, .65]$ (ventana observada) $r = [.50, .55, .60, .64, .65, .65]$ (progreso) $b=2$

Costos locales $C_{ij} = |X_i - r_j|$

	$r_1 = .50$	$r_2 = .55$	$r_3 = .60$	$r_4 = .64$	$r_5 = .65$	$r_6 = .65$
$X_1 = .50$	0	.05	.10	—	—	—
$X_2 = .50$	0	.05	.10	.14	—	—
$X_3 = .50$	0	.05	.10	.14	.15	—
$X_4 = .56$	—	.01	.04	.08	.09	.09
$X_5 = .60$	—	—	0	.04	.05	.05
$X_6 = .65$	—	—	—	.01	0	0

Verde: camino óptimo. Gris: celdas fuera de la banda $b = 2$.

Camino óptimo

Vertical: $(1, 1) \downarrow (2, 1) \downarrow (3, 1)$; costo = 0.

Diagonal: $(3, 1) \searrow (4, 2) \searrow (5, 3) \searrow (6, 4)$;
costo = $0.01 + 0 + 0.01 = 0.02$.

Horizontal: $(6, 4) \rightarrow (6, 5) \rightarrow (6, 6)$; costo = 0.

$$D_{\text{prog}} = \text{DTW}(X, r) = 0.02$$

Comparación con la meseta

$c = [.50, .50, .50, .50, .50, .50]$, $D_{\text{mes}} = \text{DTW}(X, c) = 0.31$, $\delta = 0.02 - 0.31 = -0.29 \Rightarrow$ **más cerca del progreso.**

El discriminante δ : progreso frente a meseta

Diferencia implementada

$$D_{\text{prog}} = D_1 \quad \text{y} \quad D_{\text{mes}} = D_2$$

$$\delta = D_{\text{prog}} - D_{\text{mes}} = D_1 - D_2$$

Cómo interpretar el signo

- $\delta < 0$: más cerca del **progreso**.
- $\delta \approx 0$: evidencia ambigua; observar.
- $\delta > 0$: más cerca de la **meseta**.

Ejemplo: $0.80 - 0.20 = 0.60$; la ventana se parece más a la meseta.

Condiciones de estancamiento

El cambio se considera solo si se cumplen las tres condiciones:

- 1 Sin mejora: $\text{sin_mejora} \geq 15$.
- 2 Cercanía a meseta: $D_{\text{mes}} \leq \theta_c$.
- 3 Alejamiento del progreso: $D_{\text{prog}} \geq \theta_r$ o $\delta \geq \theta_\delta$.

Además, deben confirmarse durante 3 actualizaciones consecutivas.

Dónde cambia DDTW

DDTW usa las mismas dos distancias y el mismo δ , pero sobre $\nabla x_t = x_t - x_{t-1}$. DTW compara niveles; DDTW compara cambios.

Benchmark HRES2-H₂: $W = 40$; banda ≈ 4 ; `use_ddtw=True`; `patience = 3`.

Umbral adaptativo P30/P70.

- Adriaensen, S., A. Biedenkapp, G. Shala, N. Awad, T. Eimer, M. Lindauer y F. Hutter (2022). «Automated dynamic algorithm configuration». En: *Journal of Artificial Intelligence Research* 75, págs. 1633-1699.
- Akbulut, H. (2026). «Artificial Bee Colony with Momentum-Guided Search and Starfish Exploration for Complex and Multimodal Problems». En: *Applied Soft Computing* 189, pág. 115699.
- Berndt, D. J. y J. Clifford (1994). «Using Dynamic Time Warping to Find Patterns in Time Series». En: *KDD Workshop (AAAI-94 Workshops on Knowledge Discovery in Databases)*. Vol. 398, págs. 359-370.
- Cenikj, G., A. Nikolikj, G. Petelin, N. Van Stein, C. Doerr y T. Eftimov (2026). «A survey of features used for representing black-box single-objective continuous optimization». En: *Swarm and Evolutionary Computation* 101, pág. 102288.

- Jankovic, A., D. Vermetten, A. Kostovska, J. de Nobel, T. Eftimov y C. Doerr (2022). «Trajectory-based algorithm selection with warm-starting». En: *2022 IEEE Congress on Evolutionary Computation (CEC)*. IEEE, págs. 1-8.
- Keogh, E. J. y M. J. Pazzani (2001). «Derivative Dynamic Time Warping». En: *Proceedings of the 2001 SIAM International Conference on Data Mining (SDM)*, págs. 1-11.
- Kostovska, A., A. Jankovic, D. Vermetten, J. de Nobel, H. Wang, T. Eftimov y C. Doerr (2022). «Per-run algorithm selection with warm-starting using trajectory-based features». En: *International Conference on Parallel Problem Solving from Nature*. Springer, págs. 46-60.
- Liu, X., T. Wang, Z. Zeng, Y. Tian y J. Tong (2025). «Three stage based reinforcement learning for combining multiple metaheuristic algorithms». En: *Swarm and Evolutionary Computation* 95, pág. 101935.

- Mambrini, A. y D. Sudholt (2015). «Design and analysis of schemes for adapting migration intervals in parallel evolutionary algorithms». En: *Evolutionary Computation* 23.4, págs. 559-582.
- Pei, J., Y. Mei, J. Liu, M. Zhang y X. Yao (2025). «Adaptive operator selection for meta-heuristics: A survey». En: *IEEE Transactions on Artificial Intelligence* 6.8, págs. 1991-2012.
- Reijnen, R., Z. Bukhsh, H. C. Lau, Y. Wu e Y. Zhang (2025). «Search trajectory network-enhanced multi-objective dynamic algorithm configuration». En: *ECAI 2025. Frontiers in Artificial Intelligence and Applications*. IOS Press, págs. 4921-4928.
- Talbi, E.-G. (2021). «Machine Learning into Metaheuristics: A Survey and Taxonomy». En: *ACM Computing Surveys* 54.6, págs. 1-32.
- Vega, E., R. Soto, B. Crawford, J. Peña y C. Castro (2021). «A learning-based hybrid framework for dynamic balancing of exploration-exploitation: Combining regression analysis and metaheuristics». En: *Mathematics* 9.16, pág. 1976.

- Wolpert, D. H. y W. G. Macready (1997). «No Free Lunch Theorems for Optimization». En: *IEEE Transactions on Evolutionary Computation* 1.1, págs. 67-82.